

中国大学生计算机设计大赛



软件开发类作品文档简要要求

作品编号：2025019700

作品名称：影忆智寻——基于多模态检索模型的智能相册

作者：黄乐彤、潘先胜、牛永辉、唐炜程

版本编号：1

填写日期：2025 年 4 月 20 日

填写说明：

- 1、本文档适用于所有涉及软件应用与开发类的各个小类作品，包括：(1) Web 应用与开发 (2) 管理信息系统 (3) 移动应用开发（非游戏类）(4) 算法设计与应用 (5) 企业赛项；
- 2、本文档为简要文档，不宜长篇大论，需简明扼要，建议设计二级目录，逻辑性强；
- 3、一级标题采用二号黑体，居中，二级标题采用三号黑体，靠左，根据需要可以设计三级标题，正文一律用五号宋体；
- 4、提交文档时，以 PDF 格式提交本文档；
- 5、本文档内容是正式参赛内容组成部分，务必真实填写。如不属实，将导致奖项等级降低甚至终止本作品参加比赛。
- 6、项目中涉及应用人工智能大模型的内容，务必在各个部分说明清楚。

目录

第一章 需求分析 3

1.1 开发原因 3

1.2 竞品分析 3

1.3 面向的用户 3

1.4 主要功能 4

1.5 主要性能 4

第二章 概要设计 5

2.1 功能模块与层次结构 5

2.2 核心检索类 6

2.3 多模态模型 6

2.4 前后端接口与调用设计 6

2.5 UI 介绍 6

第三章 详细设计 7

3.1 界面设计 7

3.2 数据库设计 8

3.3 关键算法 9

3.3.1 三元化方法^[1] 9

3.3.2 自蒸馏训练方法^[2] 10

3.3.3 检索方法 11

第四章 测试报告 12

4.1 模型准确性 12

4.2 模型压缩效果与推理时间 14

4.3 网站测试 16

第五章 安装及使用 17

5.1 在线访问与功能测试 17

5.2 本地部署说明 17

第六章 项目总结 18

参考文献 19

第一章 需求分析

1.1 开发原因

数据量呈现指数级增长。据 IDC 预测，到 2025 年全球每年产生的数据将超过 175 Zettabytes^[3]。在 2023 年每秒全球拍摄 5.44 万张照片，一年拍摄 1.8 万亿张照片^[4]，然而数据的爆发式增长与人工管理效率之间的矛盾日益凸显——用户在传统信息管理中需耗费大量时间进行分类、检索，这种低效操作严重制约了信息价值的释放。尤其在多模态内容处理场景中，用户亟需一种能够智能解析图像语义、精准关联跨模态信息的解决方案。影忆智寻应运而生，通过深度学习模型实现更高的准确率、更快的跨模态检索响应速度，将用户从重复性劳动中解放，进可能释放影像数据的潜在价值。

1.2 竞品分析

本项目的竞品分析聚焦于国内外主流的智能相册管理系统。

从国内市场来看，现有手机原生相册普遍存在智能化水平不足的问题，具体表现为图像识别准确率偏低、场景分类维度单一、缺乏跨设备协同能力等技术瓶颈。

国际领域以 Google Photos 为代表的竞品虽然在算法先进性方面表现突出，但其技术架构存在明显局限性：首先，其核心算法模型参数量巨大，对用户而言难以部署；其次，其云端协同机制要求持续的数据同步，这种架构在数据跨境传输过程中存在敏感信息泄露风险；更为重要的是，依据我国《数据安全法》^[5]第二十一条和《个人信息保护法》^[6]第三十八条的规定，涉及生物特征、行踪轨迹等敏感数据的存储与处理必须遵循数据本地化原则，而现有国际竞品均无法满足这一合规要求。

Table 1 竞品分析

维度	国内竞品	国际竞品	DIY 产品
示例	小米相册、华为图库	Google 相册	手动搭建已有的开源模型
特性	便于国内人民使用	准确率较高功能较为强大	灵活方便、自主性高
缺点	成本较高、模型复杂且准确性较差，不支持长语句细粒度搜索	模型复杂、对于国内用户存在安全隐患、长语句检索效果差	用户自身技术与硬件门槛高，难以部署

1.3 面向的用户

本系统面向个人用户与企业用户分别提供差异化服务。

针对个人用户群体，平台支持通过标准化接口上传影像数据至云端存储空间，依托元数据标注技术实现图像资源的结构化存储与系统化管理，从而构建具备语义检索功能的数字化影像档案库。

对于企业用户而言，本系统具备轻量化部署特性，其低硬件资源占用与高效推理性能可满足工业场景需求。在涉及敏感数据（如工业检测数据）需本地化部署的场景下，系统的快速部署能力与环境适配性优势尤为显著，能够有效降低企业端的运维成本与实施难度。

1.4 主要功能

本系统提供多模态数据管理服务，支持用户通过标准化接口上传图像文件及其关联元数据（如描述性文本、标签信息等），同时支持用户对图片集的分类管理功能。系统通过建立多维索引体系，实现了对结构化分册的智能检索支持，用户可针对特定相册执行基于内容的检索，有效提升图像资源的调用效率与管理精度。

1.5 主要性能

有四种不同规模的模型变体可供选择，体积大小分别为 570.90MB、436.04MB、267.34MB、130.16MB，在 CIRCO 基准测试中^[7]，综合评分分别为 29.73，24.83，17.22，10.25（其中 29.73 的原模型直接来自于开源的 BGE-VL^[8]为截止至 2024 年最优模型，其中准确率最低，压缩程度最大的模型（无论是模型体积优于且准确性相近于 2023 年最优的两个模型 SEARLE, CIReVL 证明了我们三元化算法的可行性）。受限于算力资源，本研究仅在开放服务器部署了体积最大的模型变体（570.90 MB），但用户可根据需求选择部署其他模型变体。通过三元化量化策略结合 BITBLAS 优化技术^[9]，本系统在保持模型性能的同时，实现了模型体积的显著压缩与推理速度的加速提升。

第二章 概要设计

2.1 功能模块与层次结构

本系统采用前后端分离架构设计，其核心架构包含两个独立模块：前端交互层与后端服务层。在后端实现层面，我们构建了检索模型抽象类作为核心功能组件，通过定义标准的 CRUD（创建、读取、更新、删除）接口规范实现数据操作的统一抽象。系统基于关系型数据库实现数据持久化存储，同时通过依赖注入机制集成检索模型类，对用户发起的 CRUD 操作进行协议编解码与语义解析，并通过检索模型类实现查询语义的语义解析与特征匹配。这种分层架构设计既保证了系统组件的松耦合特性，又通过标准化接口实现了业务逻辑与数据存储的解耦。




Fig. 1 功能组件的调用关系




Fig. 2 技术路线

2.2 核心检索类

本系统通过标准化接口封装实现了增删查（CRUD）核心功能，包含图像添加（`add_image`）、特征检索（`query`）及图像删除（`delete_image`）。添加时对输入（图像与关联文本）进行特征编码并构建索引，查询时则通过 HNSW 算法^[10]对输入编码后执行近似最近邻搜索，实现高效检索。

2.3 多模态模型

本研究基于 BGE-VL 模型^[8]的预训练基础，通过三元量化策略^[1]对模型进行参数压缩，并在 Flickr30K 数据集^[11]等多模态语料上实施自蒸馏微调^[2]，最终获得量化模型。在推理阶段，通过集成 bitblas 优化技术^[9]，实现了计算效率的显著提升。特别需要指出的是，本研究严格分离了模型训练与 CIRCO 基准测试^[7]所使用的数据集，这种非重叠数据集的训练验证架构有效保障了模型跨场景应用的泛化能力。

2.4 前后端接口与调用设计

本项目采用分层解耦架构实现多模态检索系统的高效协同。技术层面，系统将跨模态编码模型、HNSW 近似最近邻算法与 Web 服务框架进行模块化整合，通过 HTTP 协议实现组件间信息交互，确保功能扩展性与运行稳定性。

在通信机制设计层面，前后端交互基于直接 HTTP 协议调用模式。前端通过预设公网 IP 地址与端口号（`http://114.215.184.67:5000`）访问后端 Flask 服务，实现用户请求的实时响应与数据回传，在 `http://114.215.184.67:3000` 显示应用界面。系统采用 JSON 格式封装请求与响应数据，支持跨平台数据交互，形成完整的端到端解决方案。

项目通过阿里云 MySQL 数据库实现数据持久化存储与业务逻辑分离。数据库设计包含用户信息表、图像数据表及图集分类表。其中，用户表存储账号权限信息，图像表记录文件路径与多模态特征向量，图集表则实现图像的层级化分类管理。为降低存储开销，结合 MySQL 特性，本项目实施轻量化存储策略，仅将图像路径与特征向量存入数据库，原始图像文件则通过本地化管理机制存储于用户设备或阿里云服务器。

在模型服务化封装方面，团队将多模态编码器与 HNSW 检索算法封装成多模态检索模型类，定义增删查接口实现与后端的深度耦合。

具体而言，用户上传图像时，前端触发后端相关接口，后端调用模型接口生成跨模态语义向量，并通过 HNSW 算法动态维护索引结构与数据库记录。而用户发起自然语言检索时，模型将查询文本编码为语义向量，利用 HNSW 算法在预构建的索引库中执行近似最近邻搜索，即时返回依照相似度排序的检索结果。模型删除接口则实现了语义向量索引结构的动态维护，确保系统状态一致性。

2.5 UI 介绍

相册网站提供注册、登录、上传图片、搜索图片、删除图片及创建图集等基础功能，其中自然语言检索功能为本作品的核心创新点。用户可通过输入复杂语义描述（如“草地上两只奔跑的小狗”）对目标图片进行检索，系统界面即时展示高精度匹配结果，显著优于传统工具依赖基础标签或关键词的检索方式。界面设计遵循极简主义原则，提升用户交互体验。

第三章 详细设计

3.1 界面设计

本作品界面设计遵循极简便利原则，构建了以“智能相册”为核心的多模态图像管理系统。

在登录/注册界面，视觉设计上选择中性色调的办公场景背景图，通过象征专业性的蓝色系与体现亲和力暖灰色系的配色方案，平衡系统专业性与用户友好性。界面中央以“智能相册图文检索”为主标题，副标题“智能检索，任何设备可搭载”强化作品端侧部署的功能定位。同时，界面展示了作品的四个核心功能模块：“快速查询”对应本作品精准高效的语义检索功能，“功能齐全”表明作品功能的完备性，“原画备份”强调数据本地化存储优势，“多端同步”体现本作品作为相册网站的跨设备协同能力。右侧登录框包含账号与密码的输入框，底部配置“忘记密码”与“去注册”的超链接，为用户提供便利。




Fig. 3 登录/注册界面

在相册主界面，左侧侧边栏包含三个模块导航结构，分别为“照片”、“整理”和“工具”，符合层级化组织原则。主界面顶部路径栏通过导航窗口清晰展示当前操作层级，图像缩略图采用时间轴排序，单击触发全屏预览模式。右上角搜索框集成多媒体检索模型，支持用户通过自然语言检索图片。底部“上传照片”按钮设计为蓝色高亮，功能简洁清晰，便于用户上手使用。用户可通过界面左上角门形图标回到登录界面，切换账号登录。用户光标停留在图片上，显示文件夹形图集编辑按钮和垃圾桶形图片删除按钮，功能完备。用户可通过图片删除按钮将图片移动至回收站，同时可在回收站对相应图片点击恢复按钮撤销删除，便于日常使用。

在检索结果呈现界面，显示用户输入的自然语言描述文本，以及与之最相关的若干图片，便于用户检查搜索结果。



Fig. 4 相册主界面

在图集管理界面，延续主界面的模块化导航设计，主区域采用卡片式布局展示图集条目。每个图集条目包含名称、创建时间、及简要描述字段。图集上设置铅笔形编辑按钮和垃圾桶形删除按钮，功能完备。左上角“创建新图集”按钮采用绿色高亮设计增强视觉引导，便于用户迅速上手使用。

综上所述，本系统界面设计通过模块化布局、信息架构优化与可视化呈现，实现了清晰的功能分区、直观的操作流程及高效便捷用户体验。

3.2 数据库设计

本项目基于阿里云 MySQL 数据库实现数据持久化存储与业务逻辑分离，以确保数据安全性、系统可扩展性及维护灵活性。数据库设计包含用户信息表（users）、图像数据表（photos）和图集分类表（albums）三个核心实体表。

用户信息表以 id 为主键存储用户唯一标识符，包含手机号（phone）作为登录凭证（唯一约束）、加密后的密码字符串、用户创建时间戳等字段，通过哈希加密技术保障用户隐私数据安全。

图像数据表同样以 id 为主键记录图像元数据，包含图像在相册系统中的存储路径、上传时间、所属图集外键、所属用户外键及状态标记字段，通过外键约束与用户表、图集表建立关联，确保数据一致性。

图集分类表以 id 为主键实现图像层级化管理，包含图集名称、内容描述、封面路径、所属用户外键及创建时间戳字段，支持用户通过树形结构进行相册分类管理。

为降低存储开销并提升系统性能，本项目实施轻量化存储策略，仅将图像路径与特征向量存入数据库，原始图像文件则通过本地化管理机制存储于用户设备或项目部署的阿里云服务器，这一设计通过分离特征向量与原始数据，既减少数据库存储压力（特征向量体积占原始图像的 0.1%），又借助 MySQL 事务管理机制保障数据操作的原子性与一致性。

数据库初始化脚本采用模块化设计，首先建立与 MySQL 服务器的连接，随后通过 SQL 语句依次创建数据库、用户表、图集表及图像表，并设置外键约束、索引优化及默认值机制等。

通过上述设计，系统实现了数据的高效管理与存储，支持动态扩展，在多模态检索场景下具有工程可



Fig. 5 回收站界面

行性与理论有效性。

3.3 关键算法

3.3.1 三元化方法^[1]

由于在线检索模型的速度要求和体积要求，我们采用三元化方法对模型做量化处理，以期在损失可接受范围内，减小模型体积，加快模型推理速度。首先我们使用了如下公式对模型权重做三元化处理。首先我们定义了一个阈值，定义为权重的加权，用来为原始权重做三元化的基准。

$$\gamma_l = \beta \cdot \frac{1}{mn} \sum_{i=1}^m \sum_{j=1}^n |W_{ij}^l|$$

之后我们使用了如下的三元化公式，通过我们上面定义的阈值，对模型权重做切割并且量化为 1, 0, -1 三个数值。

$$\tilde{W}_{ij}^l = f(W_{ij}^l | \gamma_l) = \begin{cases} 1, & W_{ij}^l > \gamma_l \\ 0, & -\gamma_l \leq W_{ij}^l \leq \gamma_l \\ -1, & W_{ij}^l < -\gamma_l \end{cases}$$

随后我们在前向传播中使用了三元化后的权重并且加入了缩放因子使得输出与之前量级相同。这样以来我们只需要使用反向传播逐步更新 W 中的参数，就可以在迭代训练中不断更新三元化模型直到达到收敛。

$$X^{l+1} = \gamma_l \cdot \tilde{W}^l X^l$$



Fig. 6 光标停留效果

3.3.2 自蒸馏训练方法^[2]

基于三元量化模型在特征表达能力上的显著退化问题，本研究提出了一种基于自蒸馏的多模态编码器协同优化框架。该方法通过构建教师-学生模型架构，首先对文本编码器 $\mathcal{E}_T$ 与图像编码器 $\mathcal{E}_I$ 进行解耦训练：对于单模态编码器优化，采用均方误差（MSE）损失函数构建自蒸馏目标：

$$\mathcal{L}_{\text{MSE}}^I = \frac{1}{N} \sum_{i=1}^N \|\mathcal{E}_I^{\text{FP}}(I_i) - \mathcal{E}_I^{\text{TERN}}(I_i)\|_2^2$$

$$\mathcal{L}_{\text{MSE}}^T = \frac{1}{M} \sum_{j=1}^M \|\mathcal{E}_T^{\text{FP}}(T_j) - \mathcal{E}_T^{\text{TERN}}(T_j)\|_2^2$$

其中 $\mathcal{E}^{\text{FP}}$ 表示全精度原始模型， $\mathcal{E}^{\text{TERN}}$ 表示三元化模型， I_i 和 T_j 分别为图像与文本数据。训练过程中采用 Adam 优化器^[12]并配合余弦退火学习率^[13]策略，最终文本编码器训练损失收敛至 $\mathcal{L}_{\text{MSE}}^T = 0.024$ ，图像编码器收敛至 $\mathcal{L}_{\text{MSE}}^I = 0.18$ （损失曲线如图 9 和图 10 所示）。

为解决解耦训练导致的跨模态对齐问题，本研究引入跨模态对比学习机制。具体而言，构建双模态特征矩阵 $\mathbf{F}^{\text{TERN}} = [\mathcal{E}_I^{\text{TERN}} \otimes \mathcal{E}_T^{\text{TERN}}]$ 与教师模型特征矩阵 $\mathbf{F}^{\text{FP}} = [\mathcal{E}_I^{\text{FP}} \otimes \mathcal{E}_T^{\text{FP}}]$ ，通过最小化 Kullback-Leibler (KL) 散度实现特征空间对齐：

$$\mathcal{L}_{\text{KL}} = \frac{1}{K} \sum_{k=1}^K \text{KL}(p(\mathbf{F}_k^{\text{FP}}) \| q(\mathbf{F}_k^{\text{TERN}}))$$

相较于传统对比学习方法（如 CLIP 模型^[14]），本方法具有显著优势：训练过程完全解耦图文配对数据依赖，在单模态自蒸馏阶段仅需独立的图像与文本数据集，后续跨模态蒸馏阶段亦无需大规模图文对齐数据集。实验结果表明，该方法在保证模型检索精度的同时，压缩模型体积，稀疏化模型参数，验证了其在计算效率与特征表达能力间的有效平衡。



Fig. 7 检索结果呈现界面

3.3.3 检索方法

本研究采用基于 BGE 模型^[8]的多模态编码架构构建检索系统。具体而言，将图文配对数据输入 BGE 模型进行联合编码，生成统一特征空间下的特征向量，并基于特征相似度计算构建多模态特征索引库。检索阶段采用 FAISS 库^[15]实现的 HNSW 图索引算法，通过近邻搜索快速定位目标特征向量。

实验结果显示，该方法在保证检索质量的同时显著提升了计算效率：与原始模型的暴力搜索方案相比，特征检索时间降低 3 个数量级（从 $O(N^2)$ 降至 $O(N \log N)$ ），而召回率仅下降 2.1%（如图 11 所示）。该方案通过特征编码模型与高效索引的协同优化，在精度损失可控的前提下实现了检索效率的量级提升。




Fig. 8 图集界面

第四章 测试报告

4.1 模型准确性

本研究在 CIRCO 基准数据集^[7]上系统评估了不同压缩程度的模型变体性能。实验流程包含三个关键步骤：首先基于 Flickr30K 数据集^[11]完成模型训练，接下来在 CIRCO 数据集上执行独立测试。实验结果如表2所示，其中关键指标定义如下：

具体来说针对 N 个查询样本，定义以下评估指标：

- **召回率 (Recall@K)**：在检索到的 top- K 结果中正样本的比例，其值域范围为 0 到 1，数值越大表明模型在特定检索深度下的查全率越高。该指标通过调整 K 值可综合评估模型在不同检索粒度下的性能表现。

$$\text{Recall}@k = \frac{1}{N} \sum_{i=1}^N \mathbb{I}(t_i \in R_i^{(k)})$$

其中：

- t_i ：第 i 个查询对应的目标图像
- $R_i^{(k)}$ ：第 i 个查询的前 k 个预测结果集合

召回率数值越大，表明模型检索准确度越高。

- **平均查准率 (mAP@K)**：通过计算所有查询在不同召回率下的查准率 (Precision-Recall 曲线下面积)，取平均值得到的综合指标。其值域范围为 0 到 1，数值越大表明模型在全局检索任务中同时具备高查




Fig. 9 文本训练过程




Fig. 10 图像训练过程

Methods	Backbone	# Params	CIRCO mAP@5
SEARLE (Baldrati et al., 2023)	CLIP-B	165M	9.4
CIReVL (Karthik et al., 2023)	CLIP-B	12.3B [†]	14.9
LDRE (Yang et al., 2024)	CLIP-B	7.9B [†]	18.0
MagicLens-B (Zhang et al., 2024)	CLIP-B	166M	23.1
MagicLens-B [‡] (Zhang et al., 2024)	CoCa-B	267M	30.8
MMRet-Base	CLIP-B	149M	34.3

((a)) 原模型暴力搜索

	Recall	mAP
Top 5	48.38	33.56
Top 10	58.50	34.23
Top 25	71.50	36.80
Top 50	79.62	37.88

((b)) 使用 HNSW 快速检索

Fig. 11 改进的图文检索算法效果对比

准率与高查全率的平衡能力。该指标全面评估模型在不同检索难度下的整体性能表现。

$$\text{mAP}@k = \frac{1}{N} \sum_{i=1}^N \frac{\sum_{j=1}^k P(j) \cdot \mathbb{I}(R_{ij}^{(k)} \in G_i)}{\min\{|G_i|, k\}}$$

其中：

- G_i : 第 i 个查询的真实标注图像集合
- $R_{ij}^{(k)}$: 第 i 个查询的第 j 个预测结果图像
- $P(j) = \frac{1}{j} \sum_{r=1}^j \mathbb{I}(R_{ir}^{(k)} \in G_i)$: 第 j 位置的累积查准率

mAP 值越高，代表模型不仅检索准确度高，且排序质量更优。

- **mAP@10 by Semantic Aspect**: 在特定语义维度（如物体类别、场景类型等）划分的子任务中，计算模型在 top-10 检索结果的平均查准率。其值域范围同样为 0 到 1，通过细分不同语义层面的性能表现，可精准定位模型在特定视觉概念上的检索能力优势与不足。例如，在”户外场景”与”室内家具”两类语义维度上，该指标可分别量化模型在对应子集中的检索质量。

符号说明: - $\mathbb{I}(\cdot)$: 示性函数（当条件成立时取 1，否则取 0）- $|G_i|$: 集合 G_i 的元素数量 - $\min\{\cdot, \cdot\}$: 取两个参数的较小值

该公式体系通过量化不同检索深度下的查全/查准能力，构建了多维度的模型性能评估框架。

4.2 模型压缩效果与推理时间

本研究系统评估了三元量化策略对模型存储效率与检索性能的影响。实验设计包含三种量化方案：(1) 文本编码器单模态量化，(2) 图像编码器单模态量化，(3) 文本-图像双编码器全模态量化。量化后的模型参数规模与检索性能对比如表3所示。实验结果验证了所提量化方法在模型轻量化与性能保持之间的有效平衡。值得注意的是，文本编码器量化对检索性能的影响显著低于图像编码器（准确率降幅比为 1: 2.80），我们认为这是因为视觉模态敏感性更高。

Table 2 CIRCO^[7]上 Recall 和 mAP 指标对比

Metric	570.90MB	436.04MB	267.34MB	130.16MB
Recall				
Recall@5	48.38	40.50	30.25	17.25
Recall@10	58.50	53.00	41.38	23.25
Recall@25	71.50	67.88	55.12	34.12
Recall@50	79.62	74.88	64.62	43.00
mAP				
mAP@5	33.56	27.51	18.34	10.23
mAP@10	34.23	28.70	18.63	10.28
mAP@25	36.80	31.09	20.33	11.35
mAP@50	37.88	32.06	21.16	11.99
mAP@10 by Semantic Aspect				
Cardinality	33.16	30.86	16.24	10.49
Addition	35.32	29.91	19.91	12.74
Negation	36.34	26.88	21.8	11.42
Direct Addressing	34.59	29.14	17.74	9.09
Compare & Change	32.36	26.06	17.68	9.50
Comparative Statement	34.43	28.24	20.5	11.49
Statement with Conjunction	34.11	28.49	18.99	10.94
Spatial Relations & Background	37.22	32.64	21.71	12.96
Viewpoint	29.73	24.83	17.22	10.25

Table 3 在 CIRCO 测试集^[7]上我们的模型与主流模型 mAP@5 对比

Methods	Backbone	# Params	CIRCO mAP@5
SEARLE ^[7]	CLIP-B	165M	9.4
CIReVL ^[16]	CLIP-B	12.3B	14.9
LDRE ^[17]	CLIP-B	7.9B	18.0
MagicLens-B ^[18]	CLIP-B	166M	23.1
MagicLens-B ^[18]	CoCa-B	267M	30.8
MMRet-Base ^[8] (570.90MB)	CLIP-B	149M	33.56
对文本模型三元化 (436.04MB) (ours)	CLIP-B	436.04M	27.51
对图片模型进行三元化 (267.34 MB) (ours)	CLIP-B	267.34M	18.34
完全三元化 (130.16MB) (ours)	CLIP-B	130.16M	10.23

本研究进一步系统评估了模型压缩后的参数稀疏度与推理时延特性。具体而言，通过量化三元化模型中各线性层的参数稀疏度均值，以及分别测量文本编码器 $\mathcal{E}_T$ 的文本编码时延和图像编码器 $\mathcal{E}_I$ 的图像编码时延，构建完整的性能评估体系。实验结果如图12所示，三元化模型在保持高参数稀疏度的同时，显著降低了文本与图像编码的推理时延。验证了所提量化策略在计算效率优化方面的有效性。该结果表明，通过低比特量化，成功实现了模型轻量化与推理加速的协同优化。

Model	Size (MB)	Average Sparsity (%)	Inference Time (ms)	
			Text	Image
BGE-VL	570.90	0.00	0.129	0.516
Tn BGE-VL	130.16	46.95	0.125	0.498

Fig. 12 量化后参数

4.3 网站测试

团队对前端网站与后端服务间的接口进行了全面测试，采用 Postman 工具对系统功能完整性、通信稳定性及异常处理能力进行验证。针对前后端 API 接口，团队设计了完备的测试用例覆盖增删查核心操作。通过模拟用户上传图像、发起自然语言检索及删除操作，验证了前后端接口调用的正确性与模型推理服务的稳定性。测试结果表明，本网站在不同网络环境下（5G/4G/WiFi）均能稳定响应，为智能相册的工程落地提供了可靠保障。

第五章 安装及使用

5.1 在线访问与功能测试

本项目的在线相册系统已部署至服务器，用户可通过以下地址在浏览器中访问并体验系统功能：

<http://114.215.184.67:3000/>

为便于功能验证与性能评估，系统提供了预置的测试账号，具体信息如下：

- **用户名：**02025019700
- **密码：**123456

登录系统后，用户可对核心功能模块进行测试与评审，包括但不限于以下功能：

- **多模态检索功能：**支持图文联合检索，验证跨模态特征对齐能力；
- **图像管理功能：**支持图片上传、分类与检索操作。

5.2 本地部署说明

对于具备一定计算资源（如 GPU 设备）的用户，本项目提供本地化部署方案以实现更灵活的使用方式。项目组已将涉及的四个模型参数及完整源代码公开于下面链接，该组模型在内存占用率与预测准确率方面呈现差异化特征，用户可根据具体需求及硬件配置（如显存容量、计算性能等）进行适配性选择。若需在本地环境中部署系统，请通过以下提供的网络链接获取完整的源代码包：

<https://pan.baidu.com/s/1FsQqMLf861I79BVjb9J-uw?pwd=1970>

下载完成后，请参考压缩包中的 `README.txt` 文件，按照其中的详细步骤完成依赖安装与环境配置。本地部署方案旨在支持以下目标：

- 支持进一步的功能扩展与性能优化研究；
- 便于评审专家深入分析系统架构与代码实现细节。

通过上述两种访问方式，用户既可直接体验在线系统的功能特性，也可在本地环境中灵活调试与验证系统的各项技术细节，从而全面评估本作品的技术实现与应用价值。

第六章 项目总结

本作品成功构建了基于多模态检索技术的智能相册管理系统，通过深度学习方法实现图像与文本的语义关联检索，旨在解决数据爆炸时代用户面临的海量信息管理难题。项目基于全球数据量指数级增长的宏观背景，着眼于个人图像管理这一具体场景，关注传统相册工具因功能单一性与多模态处理能力不足，难以满足用户对精准检索、跨设备部署及数据安全保护需求的问题。

系统采用前后端分离架构，前端基于 Vue.js 构建响应式交互界面，后端依托 Node.js、Flask 与阿里云 MySQL 数据库实现数据持久化存储与业务逻辑分离。数据库设计包含用户信息表、图像数据表与图集分类表，通过轻量化存储策略降低了数据库存储压力。

技术层面，本项目的创新点在于实现用户输入的文本与图像的跨模态语义编码，并在海量图像库中完成实时、高精度的检索任务。团队经过广泛调研，选择采用 MegaPairs 预训练的 BGE-VL-base 模型作为基底，以实现文本与图像信息的跨模态特征提取。为完成实时、高精度的检索任务，团队提出了一种基于自蒸馏的三元量化方法对模型进行轻量化处理，并结合 BitBlas 硬件加速库以提高模型推理效率。在此基础上，采用 HNSW 近似最近邻检索算法构建多层图结构索引以实现高效快速检索。

产品设计方面，系统界面遵循极简主义原则，通过自然语言检索接口与动态加载技术，实现检索结果的即时可视化反馈，操作流程直观，用户体验良好。

未来研究方向将聚焦于以下三个方面：首先，探索基于稀疏矩阵乘法的加速优化方法，以进一步提升模型推理速度；其次，设计更加完善的增量式索引更新机制，实现对百万级图像库的实时检索支持；此外，计划引入协同过滤算法与社交网络集成技术，拓展系统在智能推荐及多用户协作场景中的功能应用。具体而言，团队将针对当前三元量化模型中未完全利用的稀疏计算特性，通过优化 SpMM 算子实现计算效率的二次突破；在检索架构层面，将改进 HNSW 算法的动态索引维护机制，支持高并发场景下的实时数据更新与低延迟检索；在功能扩展方面，将构建基于用户行为数据的推荐系统，并通过权限控制模块实现多用户相册共享与协作编辑功能，从而提升系统在社交场景中的应用价值。

综上所述，本项目通过技术创新与自主可控实践，实现了多模态检索模型的轻量化部署、快速检索响应及数据主权保障三大目标，为构建国产化智能相册系统提供了可复用的技术范式，体现了青年科研团队在“突破关键核心技术”国家战略下的实践探索价值。

参考文献

- [1] CHEN J, WU C, ZHANG S, et al. Efficient ternary weight embedding model: Bridging scalability and performance[A]. 2024.
- [2] ZHANG L, SONG J, GAO A, et al. Be your own teacher: Improve the performance of convolutional neural networks via self distillation[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 3713-3722.
- [3] GOLD J. Idc: Expect 175 zettabytes of data worldwide by 2025[EB/OL]. 2021[2025-04-16]. <https://www.networkworld.com/article/966746/idc-expect-175-zettabytes-of-data-worldwide-by-2025.html>.
- [4] 佚名. 国外照片打印连锁店 MAX Spielmann 调查显示: 日常拍摄的 90% 以上由智能手机完成[EB/OL]. 2023. <https://www.163.com/dy/article/I7UFOLBF0516DM1M.html>.
- [5] 中华人民共和国数据安全法[EB/OL]. 2021. http://www.npc.gov.cn/c2/c30834/202106/t20210610_311888.html.
- [6] 中华人民共和国个人信息保护法[EB/OL]. 2021. http://www.npc.gov.cn/npc/c2/c30834/202108/t20210820_313088.html.
- [7] BALDRATI A, AGNOLUCCI L, BERTINI M, et al. Zero-shot composed image retrieval with textual inversion[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 15338-15347.
- [8] ZHOU J, LIU Z, LIU Z, et al. Megapairs: Massive data synthesis for universal multimodal retrieval [A]. 2024.
- [9] WANG L, MA L, CAO S, et al. Ladder: Enabling efficient low-precision deep learning computing through hardware-aware tensor transformation[C/OL]//18th USENIX Symposium on Operating Systems Design and Implementation (OSDI 24). Santa Clara, CA: USENIX Association, 2024: 307-323. <https://www.usenix.org/conference/osdi24/presentation/wang-lei>.
- [10] MALKOV Y A, YASHUNIN D A. Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(4): 824-836. DOI: 10.1109/TPAMI.2018.2889473.
- [11] YOUNG P, LAI A, HODOSH M, et al. From image descriptions to visual denotations: New similarity metrics for semantic inference over event descriptions[J]. Transactions of the association for computational linguistics, 2014, 2: 67-78.
- [12] KINGMA D P, BA J. Adam: A method for stochastic optimization[A]. 2014.

-
- [13] LOSHCHILOV I, HUTTER F S. Stochastic gradient descent with warm restarts. 2016[J]. DOI: <https://doi.org/10.48550/arXiv.1608>.
 - [14] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International conference on machine learning. PmLR, 2021: 8748-8763.
 - [15] DOUZE M, GUZHVA A, DENG C, et al. The faiss library[A]. 2024.
 - [16] KARTHIK S, ROTH K, MANCINI M, et al. Vision-by-language for training-free compositional image retrieval[A]. 2023.
 - [17] YANG Z, XUE D, QIAN S, et al. Ldre: Llm-based divergent reasoning and ensemble for zero-shot composed image retrieval[C]//Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2024: 80-90.
 - [18] ZHANG K, LUAN Y, HU H, et al. Magiclens: Self-supervised image retrieval with open-ended instructions[A]. 2024.